

```
[86] prices = {}
      returns = {}

for crypto in cryptos:
    ticker = yf.Ticker(crypto)
    prices_1mo = ticker.history(start=start_date, end=end_date, interval=timeFrames[0]).Close
    returns_1mo = prices_1mo.pct_change().dropna()

    prices_1d = ticker.history(start=start_date, end=end_date, interval=timeFrames[1]).Close
    returns_1d = prices_1d.pct_change().dropna()

    if crypto not in prices:
        prices[crypto] = []
        returns[crypto] = []

    prices[crypto].append(prices_1mo)
    returns[crypto].append(returns_1mo)

    prices[crypto].append(prices_1d)
    returns[crypto].append(returns_1d)
```

در کد ۵ رمز ارز را بررسی کردم و ۲ تایم فریم یک روزه و یک ماهه را نیز بررسی کردم. در عکس اطلاعات هر ارز در timeframe دریافت کرده و ذخیره کردم.

```
for crypto in cryptos:
    plt.figure(figsize=(10,4))
    for i, tF in enumerate(timeFrames):
        plt.plot(prices[crypto][i], label=f"{tF}")
    plt.title(f"{crypto}", fontsize=20)
    plt.ylabel('Prices', fontsize=20)
    plt.legend()
    plt.show()
```

در این قسمت نمودارهای تمام crypto ها در timeframe های مختلف را چاپ کردم.

✓ ACF

```
▶ p_values = {}  
  
for crypto in cryptos:  
    for i, tF in enumerate(timeFrames):  
        result = adfuller(prices[crypto][i])  
        print(f"crypto: {crypto}, result[1]: {result[1]}, tF: {tF}")  
        p_value = result[1]  
        if p_value <= 0.1:  
            p_values[f"{crypto}, {tF}"] = p_value
```

```
📄 crypto: BTC-USD, result[1]: 0.24637004959145098, tF: 1mo  
crypto: BTC-USD, result[1]: 0.8847855278596932, tF: 1d  
crypto: ETH-USD, result[1]: 0.004095915279189181, tF: 1mo  
crypto: ETH-USD, result[1]: 0.4338634428412075, tF: 1d  
crypto: USDT-USD, result[1]: 0.139401124798061, tF: 1mo  
crypto: USDT-USD, result[1]: 0.0019003353971645154, tF: 1d  
crypto: BNB-USD, result[1]: 0.664351676000936, tF: 1mo  
crypto: BNB-USD, result[1]: 0.38330053826784727, tF: 1d  
crypto: XRP-USD, result[1]: 0.3483824579098429, tF: 1mo  
crypto: XRP-USD, result[1]: 0.37503245177282124, tF: 1d
```

در اینجا **adf test** را انجام دادم. در ادامه هر کدام که بالای ۹۰ درصد مانا بود را در لیست برای استفاده بعدی ذخیره کردم.


```
[90] min_p_value_crypto = min(p_values, key=p_values.get)  
print(f'The cryptocurrency with the smallest p-value is {min_p_value_crypto} with a p-value of {p_values[min_p_value_crypto]}')  
  
The cryptocurrency with the smallest p-value is USDT-USD, 1d with a p-value of 0.0019003353971645154
```

در اینجا نیز از بین تمام **crypto**های موجود، بهترین (ارزی که کمتری **p value** را دارد) را جدا کردم.

✓ ACF

```
acf_plot = plot_acf(bestAmountOfPvalue)  
crypto, timeFrames.index(tF)
```


```
→ ('USDT-USD', 1)
```



چاپ نمودار ACF

✓ PACF

```
[93] pacf_plot = plot_pacf(bestAmountOfPvalue)
```



چاپ نمودار PACF

✓ AR

```
✓ [94] model = ARIMA(bestAmountOfPvalue, order=(1,0,0))
```

```
✓ [95] start = time()  
      model_fit = model.fit()  
      end = time()  
      print('Model fitting time is: ', end-start)
```

Model fitting time is: 0.33434128761291504

```
✓ [96] print(model_fit.summary())
```

SARIMAX Results

Dep. Variable:	Close	No. Observations:	365
Model:	ARIMA(1, 0, 0)	Log Likelihood	2311.256
Date:	Thu, 14 Dec 2023	AIC	-4616.512
Time:	14:17:43	BIC	-4604.812
Sample:	11-01-2022 - 10-31-2023	HQIC	-4611.862
Covariance Type:	opg		

	coef	std err	z	P> z	[0.025	0.975]
const	1.0002	0.000	4157.765	0.000	1.000	1.001
ar.L1	0.8611	0.010	85.094	0.000	0.841	0.881
sigma2	1.842e-07	3.15e-09	58.549	0.000	1.78e-07	1.9e-07

با توجه به نمودار PACF، بهترین مقدار برای p ، مقدار ۱ بود. با ران کردن کد همانطور که مشخص است مقدار $P>|z|$ که به عبارتی همان p value است زیر 0.1 و این نشانه خوبی برای ماست.

MA

```
[97] model = ARIMA(prices[crypto][timeFrames.index(tF)], order=(0,0,3))
```

```
[98] start = time()
model_fit = model.fit()
end = time()
print('Model fitting time is: ', end-start)
```

Model fitting time is: 0.6195120811462402

```
[99] print(model_fit.summary())
```

```
=====
                        SARIMAX Results
=====
Dep. Variable:          Close      No. Observations:          365
Model:                 ARIMA(0, 0, 3)    Log Likelihood          2257.856
Date:                 Thu, 14 Dec 2023    AIC                   -4505.713
Time:                 14:17:43           BIC                   -4486.213
Sample:               11-01-2022         HQIC                  -4497.963
                   - 10-31-2023
Covariance Type:      opg
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
const         1.0002      0.000   8956.993    0.000      1.000      1.000
ma.L1         1.0737      0.017    62.862    0.000      1.040      1.107
ma.L2         0.7826      0.019    42.102    0.000      0.746      0.819
ma.L3         0.5254      0.018    29.040    0.000      0.490      0.561
sigma2        2.463e-07   7.48e-09    32.949    0.000   2.32e-07   2.61e-07
=====
```

به همین صورت با نگاه به نمودار ACF، مقدار ۳ مقدار مناسبی بود. با ران کردن کد، همانطور که مشخص است مقدار $P>|z|$ که به عبارتی همان p value است زیر 0.1 و این نشانه خوبی برای ماست.

▼ ARMA

```
[100] model = ARIMA(prices[crypto][timeFrames.index(tF)], order=(1,0,3))
```

```
[101] start = time()
      model_fit = model.fit()
      end = time()
      print('Model fitting time is: ', end-start)
```

Model fitting time is: 0.307051420211792

```
print(model_fit.summary())
```

SARIMAX Results

```
=====
Dep. Variable:          Close      No. Observations:          365
Model:                ARIMA(1, 0, 3)  Log Likelihood          2327.320
Date:                 Thu, 14 Dec 2023  AIC          -4642.640
Time:                 14:17:44      BIC          -4619.241
Sample:              11-01-2022      HQIC          -4633.341
                  - 10-31-2023
Covariance Type:          opg
=====
```

	coef	std err	z	P> z	[0.025	0.975]
const	1.0002	0.000	4285.399	0.000	1.000	1.001
ar.L1	0.8928	0.026	34.401	0.000	0.842	0.944
ma.L1	0.1858	0.036	5.135	0.000	0.115	0.257
ma.L2	-0.1820	0.050	-3.674	0.000	-0.279	-0.085
ma.L3	-0.1653	0.038	-4.326	0.000	-0.240	-0.090
sigma2	1.679e-07	5.31e-09	31.616	0.000	1.58e-07	1.78e-07

همان نکات قبلی (:)

▼ Test

```
train_start = '2022-11-01'
train_end = '2023-09-30'
test_start = '2023-10-01'
test_end = '2023-11-01'
```

```
[104] train_end = datetime(2023,9,30, tzinfo=timezone.utc)
      test_end = datetime(2023,11,1, tzinfo=timezone.utc)

      train_data = prices[crypto][timeFrames.index(tF)].loc[:train_end][:]
      test_data = prices[crypto][timeFrames.index(tF)].loc[train_end + timedelta(days=1):test_end]
      print(train_end)
      print(test_end)
```

بازه بندی تقسیم دیتا به train و test را در این بخش انجام دادم. به طوری که ۱۱ ماه برای train و ۱ ماه برای test گذاشتم.

```
AR

model = ARIMA(train_data, order=(1,0,0))

[106] start = time()
      model_fit = model.fit()
      end = time()
      print('Model fitting time is: ', end-start)


Model fitting time is: 0.1866466999053955

[107] pred_start_date = test_data.index[0]
      pred_end_date = test_data.index[-1]
      test_data.index[-1]

Timestamp('2023-10-31 00:00:00+0000', tz='UTC')

[108] predictions = model_fit.predict(start=pred_start_date, end=pred_end_date)
      residuals = test_data - predictions
```

حال با همان مقادیر order قبلی مدل را با ۱۱ ماه آموزش و برای ۱ ماه آینده عمل پیش‌بینی را انجام دادم.



MAPE

```
[111] print('Mean absolute percent error (MAPE):', np.mean(abs(residuals/test_data)))
```

```
Mean absolute percent error (MAPE): 0.00021509993688424687
```

MSE


```
[112] print('Mean Squared Error (MSE):', np.mean(residuals**2))
```

```
Mean Squared Error (MSE): 6.072486496603657e-08
```

دو معیار محاسبه ارور خواسته شده در سوال

در ادامه همین کار را برای MA و ARMA نیز انجام دادم و صرفا خروجی نموداری را قرار میدهم:

:MA



MAPE

```
[118] print('Mean absolute percent error (MAPE):', np.mean(abs(residuals/test_data)))
```


```
Mean absolute percent error (MAPE): 0.00022763869163227096
```

MSE

```
[119] print('Mean Squared Error (MSE):', np.mean(residuals**2))
```

```
Mean Squared Error (MSE): 6.863598464636257e-08
```

ARMA



▼ MAPE

```
[125] print('Mean absolute percent error (MAPE):', np.mean(abs(residuals/test_data)))
```

Mean absolute percent error (MAPE): 0.00021602185511825452

▼ MSE

```
[126] print('Mean Squared Error (MSE):', np.mean(residuals**2))
```

Mean Squared Error (MSE): 6.287599006872623e-08

Q3

```
[127] def ar_model(p):  
    model = ARIMA(train_data, order=(p,0,0))  
    model_fit_predict = model.fit()  
    predictions = model_fit_predict.predict(start=pred_start_date, end=pred_end_date)  
    residuals = test_data - predictions  
    return residuals
```

```
[128] def ma_model(q):  
    model = ARIMA(train_data, order=(0,0,q))  
    model_fit_predict = model.fit()  
    predictions = model_fit_predict.predict(start=pred_start_date, end=pred_end_date)  
    residuals = test_data - predictions  
    return residuals
```




```
[129] def arma_model(p, q):  
    model = ARIMA(train_data, order=(p,0,q))  
    model_fit_predict = model.fit()  
    predictions = model_fit_predict.predict(start=pred_start_date, end=pred_end_date)  
    residuals = test_data - predictions  
    return residuals
```

در این قسمت ۳ مدل را در function نوشتم.

```
[130] B_p = [0, 0, 0]  
    B_q = [0, 0, 0]  
    B_MAPE = [1, 1, 1]  
    B_MSE = [1, 1, 1]  
    B_res = []  
  
    for p in range(1, 16):  
        print(f"p: {p}")  
        for q in range(1, 16):  
            residuals = [ar_model(p), ma_model(q), arma_model(p, q)]  
            for i, res in enumerate(residuals):  
                MAPE = np.mean(abs(res/test_data))  
                MSE = np.mean(res**2)  
                if MAPE < B_MAPE[i] and MSE < B_MSE[i]:  
                    B_MAPE[i] = MAPE  
                    B_MSE[i] = MSE  
                    if i == 0:  
                        B_p[i] = p  
                        B_q[i] = 0  
                    elif i == 1:  
                        B_q[i] = q  
                        B_p[i] = 0  
                    else:  
                        B_p[i] = p  
                        B_q[i] = q  
            print(f"Best p: {B_p}, Best q: {B_q}, B_MAPE[i]: {B_MAPE[i]}, B_MSE[i]: {B_MSE[i]}")
```

در اینجا همان خواسته سوال که brute force زدن روی مقادیر p و q بود را انجام دادم. تعریف لیست‌ها صرفاً بخاطر کم کردن محاسبات تکراری‌ست. اینکار برای هر ۳ مدل تعریف شده در همین قسمت انجام می‌شود.

حال با مقادیر p و q به دست آمده مدل‌های را ران میکنیم.



همانطور که مشخص است نمودارها به شدت بهتر از حالت قبل به دست آمده‌اند و فیت‌تر شده‌اند.

```
➡ for AR:  
MSE: 6.033112318708502e-08  
MAPE: 0.00021495818080776485  
  
for MA:  
MSE: 5.708712843912922e-08  
MAPE: 0.00020583432504083069  
  
for ARMA:  
MSE: 5.1861016827461545e-08  
MAPE: 0.0001853195455084196
```

با مقایسه این اعداد با حالت قبل مشاهده می‌شود مقادیر خطا هم به نسبت کمتر شده‌اند و شاهد خطای کمتری هستیم.