

```

Get Data

cryptos = ['BTC-USD', 'ETH-USD', 'BNB-USD', 'SOL-USD', 'XRP-USD', 'USDC-USD', 'STETH-USD', 'ADA-USD', 'AVAX-USD', 'DOGE-USD', 'DOT-USD', 'WTRX-USD', 'TRX-USD', 'MATIC-USD', 'LINK-USD']

prices = {}
returns = {}

start_date = datetime(2022, 11, 1)
end_date = datetime(2023, 11, 1)

for crypto in cryptos:
    ticker = yf.Ticker(crypto)
    prices_1h = yf.download(crypto, start=start_date, end=end_date, interval='1h')
    prices_4h = prices_1h.groupby(pd.Grouper(freq='4H')).agg(['Open': 'first', 'High': 'max', 'Low': 'min', 'Close': 'last', 'Volume': 'sum'])
    prices_4h = prices_4h.fillna(method='ffill')

    if crypto not in prices:
        prices[crypto] = {}
        returns[crypto] = {}

    prices[crypto] = prices_4h['Close']

```

در اینجا داده‌های موردنیاز برای تحلیل پروژه را در بازه زمانی ۴ ساعته ذخیره می‌کنیم. چون بازه ۴ ساعته در `interval`ها موجود نیست از این ساختار برای این تبدیل استفاده می‌کنیم.

```

[ ] def check_cointegration(df):
    result = coint_johansen(df, det_order=0, k_ar_diff=1)
    if np.all(result.lr1 > result.cvt[:, 1]):
        return result
    else:
        return None

```

با استفاده از این تابع سری‌های زمانی که `stationary` هستند را مشخص می‌کنیم. اینکار به کمک `coint_johansen` انجام می‌گیرد. با بررسی اینکه آیا همه آمارهای `trace` از مقادیر بحرانی خود فراتر می‌روند (با استفاده از `np.all`)، این تابع تأیید می‌کند که یک ترکیب خطی `stationary` در بین متغیرها وجود دارد. اگر سری مانا باشد، `result` را برمیگردانیم تا بتوانیم مقادیر `weights` را محاسبه کنیم.

Generate Combination of Time Series

```
df = pd.DataFrame(prices)

def generate_stationary_series(df, max_len=4):
    stationary_series = []
    cols = list(df.columns)
    for i in range(2, max_len+1):
        combinations = list(itertools.combinations(cols, i))
        for combination in combinations:
            result = check_cointegration(df[list(combination)])
            if result is not None:
                stationary_series.append(combination)
                normalized_weights = result.evec[:, 0] / result.evec[:, 0][0]
                weights[f'{combination}'] = normalized_weights
                results_of_cointegration[f'{combination}'] = result
    return stationary_series
```

در اینجا سری‌های زمانی جدید را تولید کردیم. به این صورت که با استفاده از `itertools` سری‌های زمانی را با تعداد معین ترکیب کردیم. سپس چک می‌کنیم که اگر سری مانا باشد، آن را به عنوان سری `stationary` ذخیره می‌کنیم. همچنین وزن‌های سری جدید و کلا `result` را برای استفاده در مراحل بعدی ذخیره می‌کنیم. دلیل `normal` کردن داده‌ها این است که معمولاً یک عضو وزن‌ها را ۱ می‌گذارند و بقیه وزن‌ها با توجه به آن مقدار می‌گیرند.

Compute Price of Time Series

```
combination_of_timeseries = {}
for key, weight in weights.items():
    val = key.split(',')
    cleaned_list = [s.replace('(', '').replace(')', '').replace(' ', '').replace('"', '') for s in val]
    time_series = df[cleaned_list].dot(weights[key])
    if f'{cleaned_list}' not in combination_of_timeseries:
        combination_of_timeseries[f'{cleaned_list}'] = {}
        combination_of_timeseries[f'{cleaned_list}']['value'] = time_series
```

در اینجا قیمت سری زمانی را به دست آوردم. به این صورت که وزن‌ها را از قبل ذخیره کرده بودم و در اینجا آن را با قیمت سری‌های زمانی ضرب نقطه‌ای و سپس حاصل را به صورت یک دنباله اعداد که همان نرخ سری زمانی جدید است ذخیره کردم.

▼ Compute P Value

```
[ ] coint_series_pvalues = {}  
    for key, val in combination_of_timeseries.items():  
        ad_fuller_result = adfuller(combination_of_timeseries[key]['value'])  
        series_pvalue = ad_fuller_result[1]  
        combination_of_timeseries[key]['p_value'] = series_pvalue
```

در اینجا نیز مقدار p value را با استفاده از adfuller به دست آورده و ذخیره کردم.

▼ Selection

```
[ ] sorted_combination_of_timeseries = {k: v for k, v in sorted(combination_of_timeseries.items(), key=lambda item: item[1]['p_value'])}  
    items = list(sorted_combination_of_timeseries.items())  
    sliced_items = items[:10]  
    sorted_combination_of_timeseries = dict(sliced_items)  
    for key, val in sorted_combination_of_timeseries.items():  
        print(sorted_combination_of_timeseries[key]['p_value'])
```

در اینجا سری زمانی با کمترین مقدار p value را انتخاب کردم و سایر محاسبات را فقط بر روی همین مقادیر انجام دادم.

▼ Compute Hurst Exponents

```
[ ] hurst_exponents = {}  
    for key, val in sorted_combination_of_timeseries.items():  
        H, c, data = compute_Hc(sorted_combination_of_timeseries[key]['value'])  
        sorted_combination_of_timeseries[key]['hurst_exponents'] = H
```

در اینجا نیز Hurst Exponent را با استفاده از تابع از پیش آماده compute_Hc محاسبه و سپس ذخیره کردم.

✓ Compute Half Life Time

```
[ ] def compute_half_life(series):  
    price = pd.Series(series)  
    lagged_price = price.shift(1).fillna(method="bfill")  
    delta = price - lagged_price  
    beta = np.polyfit(lagged_price, delta, 1)[0]  
    half_life = -np.log(2) / beta  
    return half_life
```

تابع ابتدا سری ورودی را به یک `pandas.Series` تبدیل می کند. سپس، سری `lagged price` را با جابجایی سری قیمت به اندازه یک دوره و پر کردن مقادیر `Nan` محاسبه می کند. این سری قیمت با تاخیر در متغیر `lagged_price` ذخیره می شود.

سپس تابع `delta` را برای هر دوره با کم کردن `lagged price` از قیمت فعلی محاسبه می کند. این در متغیر `delta` ذخیره می شود.

در مرحله بعد، تابع یک مدل رگرسیون خطی از شکل $\text{delta} = \text{beta} * \text{lagged_price} + \text{epsilon}$ را با سری `lagged_price` و `delta` با استفاده از تابع `polyfit` مطابقت می دهد. ضریب `beta` که نشان دهنده شیب خط رگرسیون است در متغیر `beta` ذخیره می شود.

در نهایت، تابع نیمه عمر سری زمانی را با استفاده از فرمول $-\text{np.log}(2) / \text{beta}$ محاسبه می کند. این فرمول مبتنی بر این واقعیت است که نیمه عمر زمانی است که طول می کشد تا مقدار سری به نصف از مقدار اولیه آن کاهش یابد. مدل فروپاشی نمایی فرض می کند که نرخ کاهش متناسب با مقدار فعلی است که توسط ضریب `beta` گرفته می شود.

	['XRP-USD', 'USDC-USD', 'DAI-USD', 'LEO-USD']	['XRP-USD', 'USDC-USD', 'DAI-USD', 'LTC-USD']	['USDC-USD', 'DAI-USD', 'LTC-USD', 'ETC-USD']	['ETH-USD', 'USDC-USD', 'DAI-USD', 'CRO-USD']	['USDC-USD', 'STETH-USD', 'DAI-USD', 'CRO-USD']	['USDC-USD', 'DAI-USD', 'LEO-USD', 'XLM-USD']	['USDC-USD', 'DAI-USD', 'OKB-USD', 'XMR-USD']	['USDC-USD', 'AVAX-USD', 'DAI-USD', 'NEAR-USD']	['USDC-USD', 'DAI-USD', 'OKB-USD', 'STX4847-USD']	['XRP-USD', 'USDC-USD', 'DAI-USD', 'XLM-USD']
value	Datetime 2022-11-01 00:00:00+00:00 105.7272...	Datetime 2022-11-01 00:00:00+00:00 168.9372...	Datetime 2022-11-01 00:00:00+00:00 -0.127528...	Datetime 2022-11-01 00:00:00+00:00 303450.5...	Datetime 2022-11-01 00:00:00+00:00 -0.126828...	Datetime 2022-11-01 00:00:00+00:00 -0.125378...	Datetime 2022-11-01 00:00:00+00:00 -0.125610...	Datetime 2022-11-01 00:00:00+00:00 -0.127816...	Datetime 2022-11-01 00:00:00+00:00 -0.128788...	Datetime 2022-11-01 00:00:00+00:00 82.10259...
p_value	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
hurst_exponents	0.490125	0.489499	0.490151	0.490556	0.49042	0.490527	0.490698	0.489763	0.489541	0.490164
half_lives	0.970305	0.968121	0.968485	0.973068	0.971763	0.97612	0.975788	0.972203	0.969534	0.975963

نتایج نهایی فرایند (مقادیر p_value صفر در واقع e^{-28} هستند که در جدول 0 نوشته شده‌اند)

همانطور که مشخص است چون hurst exponent از ۰,۵ کوچک‌تر است، پس سری ماناست.